

Maschinelles Lernen: Prüfungsstudienarbeit

Sommersemester 2026

Prof. Dr. Robert Hable

Themenstellung:

In der Projektarbeit sollen Sie in 2er-Gruppen ein überwachtes Lernproblem anhand eines realen Datensatzes bearbeiten und die Ergebnisse präsentieren:

1. **Bis 13. Mai 2026:** Bilden Sie eine 2er-Gruppe und suchen Sie sich einen Datensatz. Hierfür haben Sie folgende drei Möglichkeiten

- (a) UCI Machine Learning Repository:

<https://archive.ics.uci.edu/ml/datasets.php>

- (b) kaggle:

<https://www.kaggle.com/datasets>

Beachten Sie bei der Wahl des Datensatzes bitte folgende Punkte:

- Wenn Sie einen Datensatz vom UCI Machine Learning Repository wählen: Es darf kein Datensatz verwendet werden, der auch in der Vorlesung verwendet wurde / wird. (Die betreffenden Datensätze finden Sie im iLearn im Ordner “Daten”.)
- Wenn Sie einen Datensatz von kaggle wählen: Früher war kaggle eine sehr gute Quelle für eine Unmenge an Datensätzen. Allerdings befinden sich mittlerweile sehr viele (sehr schlecht) gefälschte Datensätze auf kaggle. Da es offensichtlich nicht einmal eine rudimentäre Qualitätskontrolle gibt, ist die Gefahr mittlerweile groß einen gefälschten Datensatz zu erwischen. Unechte Datensätze (zumal wenn schlecht gefälscht) werfen wenig Material für eine gewinnbringende Analyse ab. Wenn Sie einen Datensatz von kaggle verwenden, dann prüfen Sie bitte zunächst, ob der Datensatz möglicherweise eine Fälschung ist!

- Der gleiche Datensatz darf nicht von verschiedenen Gruppen bearbeitet werden. Um einen Datensatz für Ihre Gruppe zu reservieren, schreiben Sie im iLearn unter der Rubrik “Prüfungsstudienarbeit” einen Eintrag in das Forum “Themenmeldung”. Nennen Sie im Betreff Ihre Namen und den Namen des gewählten Datensatzes sowie die Quelle (UCI oder kaggle). Sobald eine Gruppe die Wahl eines Datensatzes per Forumsnachricht verkündet, ist dieser Datensatz für alle anderen gesperrt.
- Achten Sie bei der Wahl des Datensatzes darauf, dass er für ein überwachtes Lernproblem geeignet ist, also Klassifikation oder Regression.
- Damit der Datensatz für maschinelles Lernen geeignet ist, sollte er nicht zu klein sein (d.h. genügend große Anzahl an Zeilen im Datensatz).

2. Führen Sie eine Analyse des Datensatzes mit R durch. Hierzu gehört:

- eine deskriptive Analyse (mit Hilfe von statistischen Kennzahlen und grafischen Darstellungen)
- die Bearbeitung eines überwachten Lernproblems mit drei alternativen Lernverfahren

Achten Sie dabei darauf, dass Sie die Analyse nach allen Regeln der Kunst durchführen. Hierzu gehören insbesondere:

- eine deskriptive Analyse, die auf das überwachte Lernproblem ausgerichtet ist (dazu gehören insbesondere Auswertungen im Hinblick auf die spätere Zielvariable)
- die adequate Wahl von Gütemaßen
- eine geeignete Aufteilung in Trainings- und Testdaten
- eine Einstellung von Tuningparametern (sofern vorhanden) mit geeigneten Verfahren

3. Ab dem 29. Juni 2026 finden in der Vorlesung dann die Abschlusspräsentationen mit Präsentationsfolien statt (Vorlesungen am Montag, den 29. Juni, und am Mittwoch, den 1. Juli). Beim Vortrag sollte der Redeanteil zwischen den Gruppenmitglieder ausgewogen sein. Im Anschluss an die Präsentation erfolgt eine fachliche Diskussion über die

Arbeit. Je Gruppe stehen voraussichtlich insgesamt ca. 20 min (einschließlich Diskussion) zur Verfügung.

Der Vortrag muss insbesondere folgende Punkte enthalten:

- Vorstellung des Datensatzes und Zweck der Analyse¹
- Vorstellung und Analyse der Ergebnisse der deskriptiven Analyse
- Vorstellung und Analyse der Ergebnisse der drei alternativen Lernverfahren für das überwachte Lernproblem, begründete Empfehlung für eines der drei Verfahren

Hinweis: Die Präsentationsfolien müssen im Wesentlichen selbsterklärend sein und alle wesentlichen Analyse-Ergebnisse enthalten.

4. Abgabe: Abzugeben sind **bis spätestens 25. Juni 2026 über iLearn:**

- die Präsentationsfolien²
- ein R-Code zusammen mit dem Datensatz (im csv-Format), aus dem sich die in der Präsentation gezeigten Ergebnisse reproduzieren lassen

Bewertungskriterien sind insbesondere:

- die Wahl des Datensatzes (Komplexität des Problems³, Eignung für überwachtes Lernen zur Lösung einer realitätsnahen Praxisproblems)
- die deskriptive Analyse (im Hinblick auf das überwachte Lernproblem)
- die Bearbeitung des überwachten Lernproblems samt Ergebnisanalyse (Die bloße Wiedergabe von Berechnungsergebnissen ist keine Analyse!)

¹Gemeint ist: Was ist hier das überwachte Lernproblem und zu welchem Zweck (z.B. in einem Unternehmen) können die Ergebnisse verwendet werden (Use Case!)

²Sie müssen zusätzlich zu den Präsentationsfolien keine Text-Ausarbeitung im Sinne eines Ergebnisberichts verfassen. In Unternehmen ist das auch nicht üblich. Dafür sollten die Präsentationsfolien aber einigermaßen selbsterklärend sein und alle wesentlichen Punkte beinhalten.

³Je komplexer der Datensatz ist, desto schwerer ist die Aufgabenstellung. Über die Wahl des Datensatzes können Sie daher selbst bis zu einem gewissen Grad die Schwierigkeit der Aufgabenstellung beeinflussen. Bei der Bewertung wird das natürlich berücksichtigt. Es ist sicherlich ratsam, keinen allzu einfachen Datensatz zu verwenden. Aber achten Sie bitte auch darauf, dass Sie sich nicht durch die Wahl eines zu komplexen Problems verheben.

- die Präsentationsfolien und der R-Code (Korrektheit, Lesbarkeit und Strukturierung, Kommentierungen)

Achtung: Der Sinn dieser Prüfungsstudienarbeit ist, dass Sie ein Praxisproblem ähnlich wie in einem Unternehmen lösen und Ergebnisse präsentieren. Gefragt ist in der Präsentation also nicht eine technische Darstellung Ihrer Programmierkenntnisse, sondern eine ergebnisorientierte inhaltliche Analyse des Praxisproblems. Eine technische auf Programmier- und Implementierungsfragen ausgerichtete Präsentation führt in jedem Fall zu einer schlechten Note – auch wenn Sie noch so bahnbrechende Raketentechnik verwenden.